

Обзор подходов к моделированию VBR потоков

25 апреля 2014 г.

Введение

При проектировании сети необходимо учитывать характер входной нагрузки. Тестировать сеть на реальных видео слишком затратно, а к достаточно полным (и объёмным) базам трейсов доступ может быть ограничен.

Одним из решений этой проблемы является моделирование входного потока с учётом его статистических свойств и анализ сети с помощью модели.

A Survey of VBR Video Traffic Models [Tanwir, Perros] (2013)

Характеристики видеопотока

Моделируемым потоком является поток размеров кадров на выходе кодера для видеоконференции (говорящая голова).

- ▶ “Куполообразное” распределение размеров кадров
- ▶ Ярко выраженная автокорреляция, имеющая экспоненциальный характер убывания

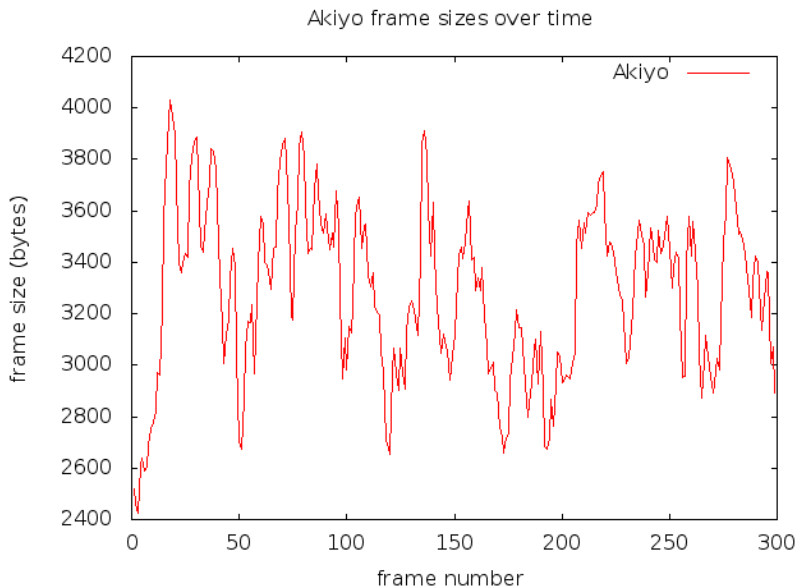


Рис.: Размеры кадров от времени (Akiyo)




Рис.: Гистограмма размеров кадров (Akiyo)

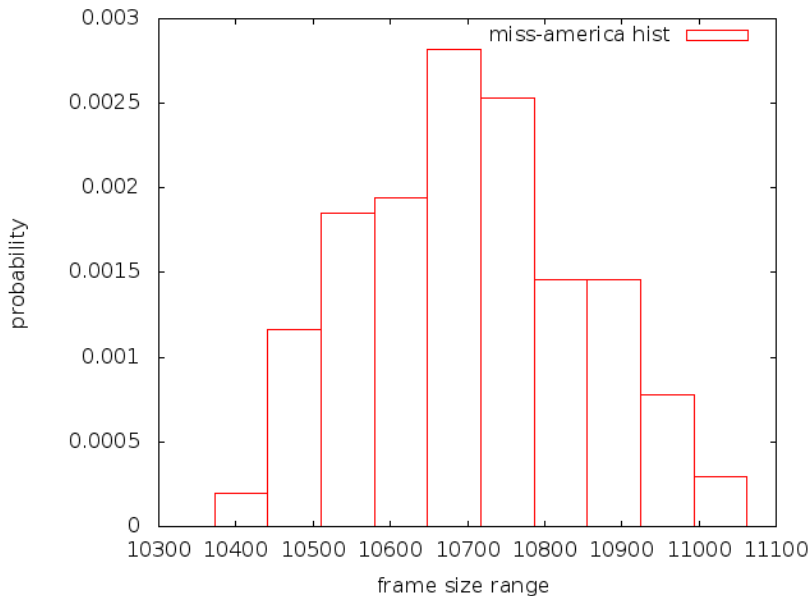


Рис.: Гистограмма размеров кадров (Miss America)

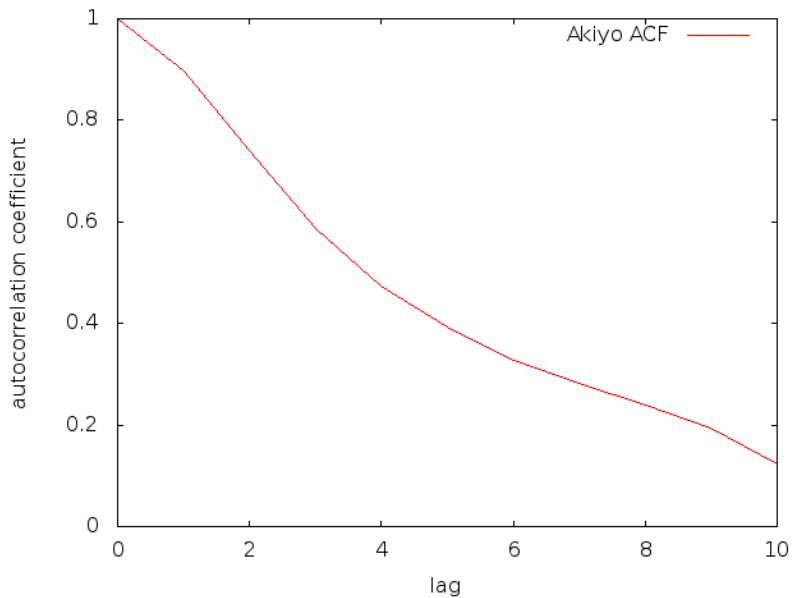


Рис.: Автокорреляционная функция, zoom-in (Akiyo)

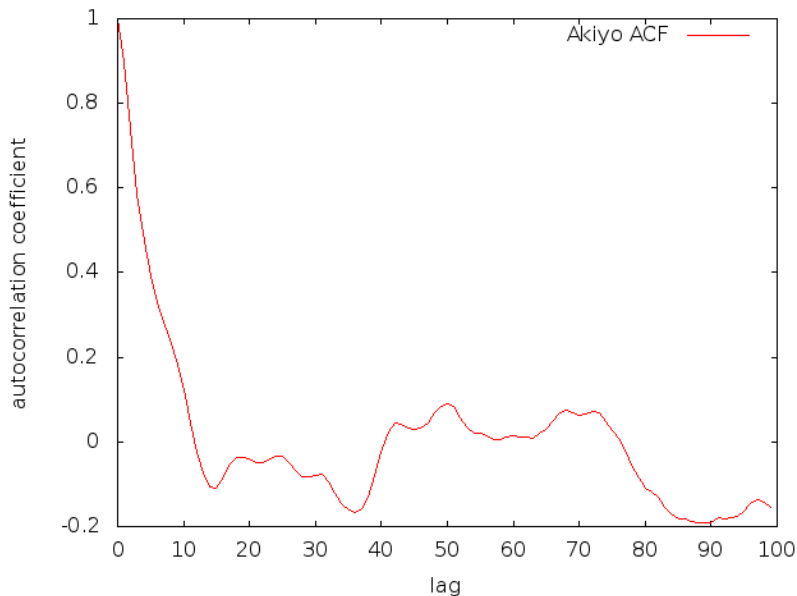


Рис.: Автокорреляционная функция, zoom-out (Akiyo)

Критерии выбора (и создания) моделей

- ▶ Различные типы кадров: Да
- ▶ Автокорреляционные характеристики: Да
- ▶ Short-Range Dependencies (SRD): Да
- ▶ Long-Range Dependencies (LRD): Нет
- ▶ Смена сцены: Нет
- ▶ Interleaved (Multiple) sources: ?
- ▶ “Универсальность” vs Количество параметров: ?
- ▶ “Хвост” распределения: ?

Классификация моделей

- ▶ Авторегрессионные модели
- ▶ Марковские модели
- ▶ Самоподобные (self-similar) и ARIMA
- ▶ Вейвлетные модели
- ▶ Прочие ($M/G/\infty$, TES etc)

Авторегрессионные модели

- ▶ AR. Взвешенная сумма + “остаточный процесс” (residual process)

$$x(n) = \sum_{i=1}^p a_i x(n-i) + e(n)$$

- ▶ DAR(p). Нужно распределение вероятностей (Y_n) и автокорреляционная функция (A_n). Считается, что DAR(1) подходит только для множественных каналов (multiple source). Почему?

$$X_n = V_n X_{n-A_n} + (1 - V_n) Y_n$$

- ▶ Frame-Based AR. Надстройка над AR для учёта смены сцен.

Авторегрессионные процессы отлично описывают трафик видеоконференции, но плохо подходят для full motion. Можно подбирать “базовое” распределение, подстраиваясь под специфику моделируемого потока (Normal, Lognormal, Gamma, Pearson V, Negative binomial, Gamma/Pareto etc).

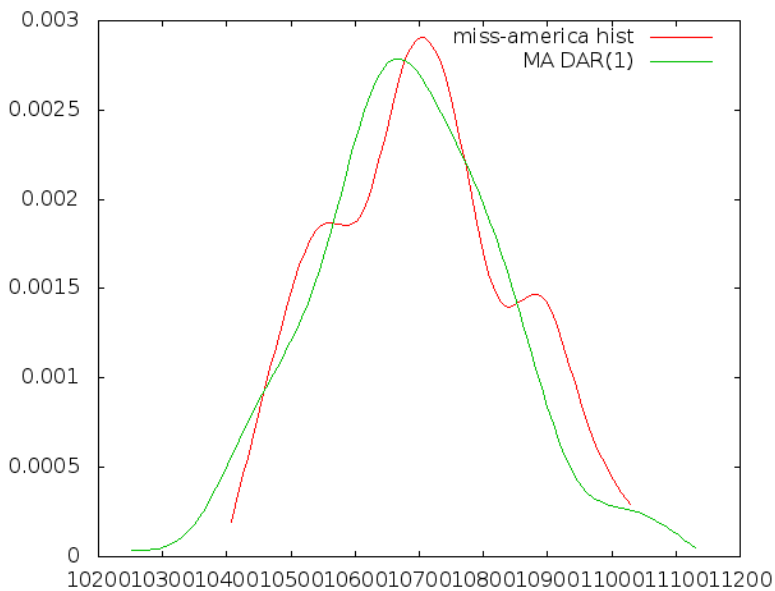


Рис.: DAR(1) vs Trace, гистограмма (MA)

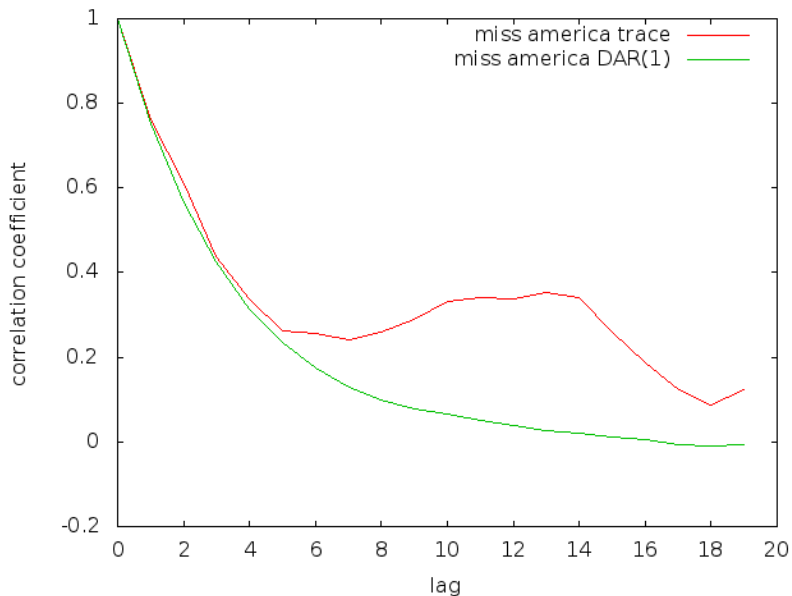


Рис.: DAR(1) vs Trace, автокорреляционная функция (MA)

Марковские модели

Текущее состояние “доминирующего процесса” зависит только от предыдущего состояния. Марковский процесс часто контролирует параметры некоторого другого процесса, например, авторегрессионного.

- ▶ State = GOP Size
- ▶ State = Scene class
- ▶ State = Frame size (a lot of states)

Конкретные примеры:

- ▶ Markov Renewal Process Model (MRP) (equidistant)
- ▶ Markov-Modulated AR Models (scene changes)
- ▶ Markov-Modulated Gamma Model (scene changes)

Большая часть марковских моделей была создана для учёта смены сцен в видеопоследовательностях. Подбор параметров является сложной задачей (иногда подбор границ активности сцен осуществляется вручную!). Алгоритм Макса-Ллойда для MRP?

Самоподобные (self-similar) модели

LRD (Long-Range Dependent) процесс является самоподобным, если для любых значений смещения и после усреднения по блокам любой длины m коэффициент автокорреляции остаётся неизменным.

Long-Range Dependence (зависимость с большой памятью - авт.) — явление, при котором текущие значения случайного процесса сильно коррелированы со значениями, удалёнными во времени.

Степень зависимости во времени характеризуется параметром Хёрста $0.5 < H < 1$. Этот параметр оценивается по трейсу и подаётся на вход самоподобному случайному процессу.

Самоподобные модели разрабатывались для full motion. Неспособны точно отражать SRD. Характеризуются степенной ACF. Для трафика видеоконференций типичное значение параметра Хёрста – 0.6.

Вейвлетные модели

- ▶ Применяем вейвлетное преобразование к трейсу
- ▶ Оцениваем корреляцию коэффициентов вейвлетного преобразования
- ▶ Генерируем новые коэффициенты WT на основе построенной модели
- ▶ Применяем обратное вейвлетное преобразование, получаем синтезированный трейс.

В чём особенности и преимущества вейвлетных моделей:

- ▶ Не требуется дополнительной надстройки для учёта смены сцен
- ▶ Точно отражает как близкие, так и дальние зависимости
- ▶ Дальние зависимости по времени переходят в близкие зависимости коэффициентов преобразования.

Трафик видеоконференций не LRD (подтвердить). Вейвлетные модели представляются избыточными.

- ▶ ACF for LRD: $\rho(k) = k^{-\beta} = e^{-\beta \log k}$
- ▶ ACF for Markov: $\rho(k) = e^{-\beta k}$
- ▶ Best fit ACF: $\rho(k) = e^{-\beta \sqrt{k}}$

Для процесса M/G/*infty* авторы аналитически вывели pmf для G так, чтобы количество занятых серверов обладало требуемыми автокорреляционными характеристиками. Далее производится преобразование полученной случайной величины таким образом, чтобы свести распределение вероятностей к целевому (Gamma/Pareto).

ACF для видеоконференций хорошо моделируется экспоненциальным законом (AR/Markovian подходят), необходимость в данной модели под вопросом.

Методы сравнения моделей

- ▶ Статистические критерии
 - ▶ Q-Q plot
 - ▶ первые два момента
 - ▶ ACF
- ▶ QoS network metrics (!)
 - ▶ Loss Rate
 - ▶ Delay
 - ▶ Jitter

Статистические критерии дают немного информации о порядке следования кадров (SRD?). Схожесть модели и исходного трейса оценивают по их поведению при симуляции передачи по сети.




Рис.: Leaky bucket, literally

Выводы, TODO

- ▶ Большая часть моделей “мимо кассы”.
- ▶ Проверить LRD
- ▶ Важен ли “хвост” основного распределения?
- ▶ Нормально ли ACF аппроксимируется экспонентой?
- ▶ Никто не публиковал сравнения на основе QoS-параметров IP-сетей (в обзорной статье это записано в FW).
- ▶ Оптимальное квантование для MRP - хорошая идея?
- ▶ Почему DAR не подходит для single-source?
- ▶ Нигде не использовался $\text{DAR}(p) + \text{Gamma/Pareto}$